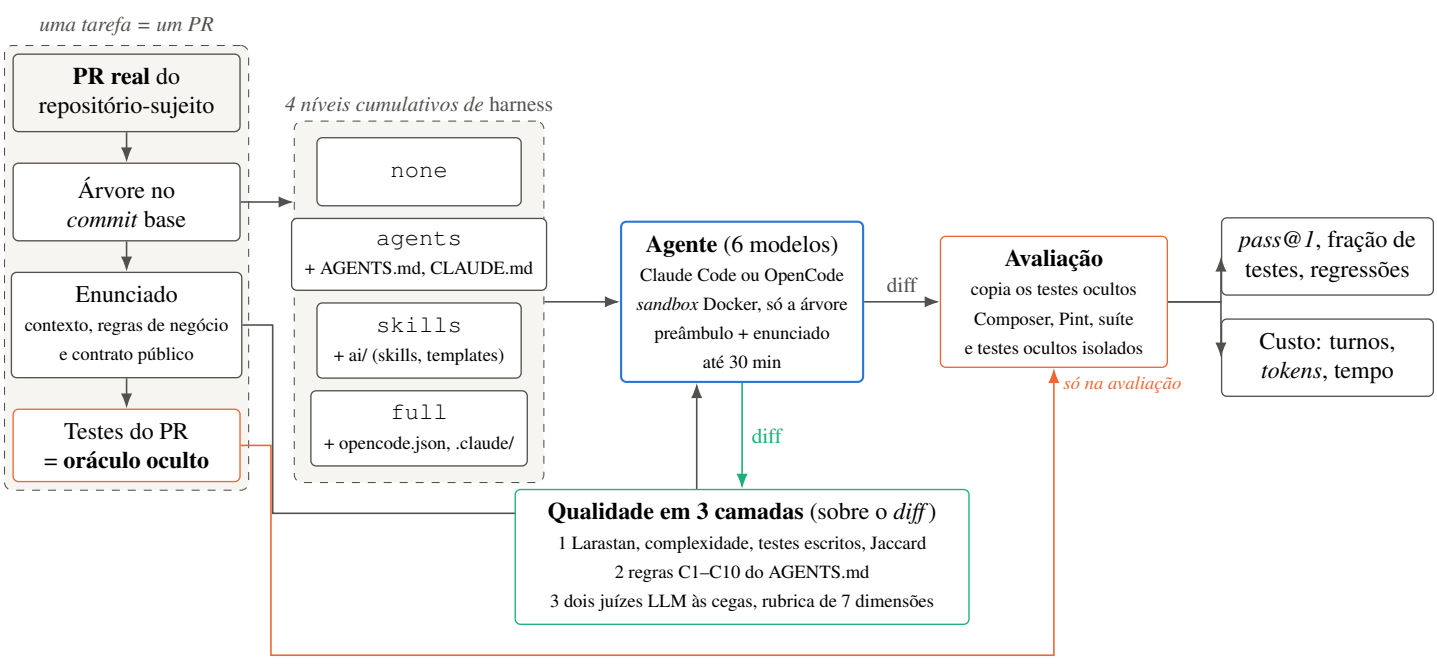
uma tarefa = um PR
PR real do repositório-sujeito
Árvore no commit base
Enunciado
contexto, regras de negócio e contrato público
Testes do PR = oráculo oculto
4 níveis cumulativos de harness
none
agents
+ AGENTS.md, CLAUDE.md
skills
+ ai/ (skills, templates)
full
+ opencode.json, .claude/
Agente (6 modelos)
Claude Code ou OpenCode
sandbox Docker, só a árvore
preâmbulo + enunciado
até 30 min
diff
Avaliação
copia os testes ocultos
Composer, Pint, suíte
e testes ocultos isolados
só na avaliação
pass@1, fração de testes, regressões
Custo: turnos, tokens, tempo
diff
Qualidade em 3 camadas (sobre o diff)
1 Larastan, complexidade, testes escritos, Jaccard
2 regras C1–C10 do AGENTS.md
3 dois juízes LLM às cegas, rubrica de 7 dimensões