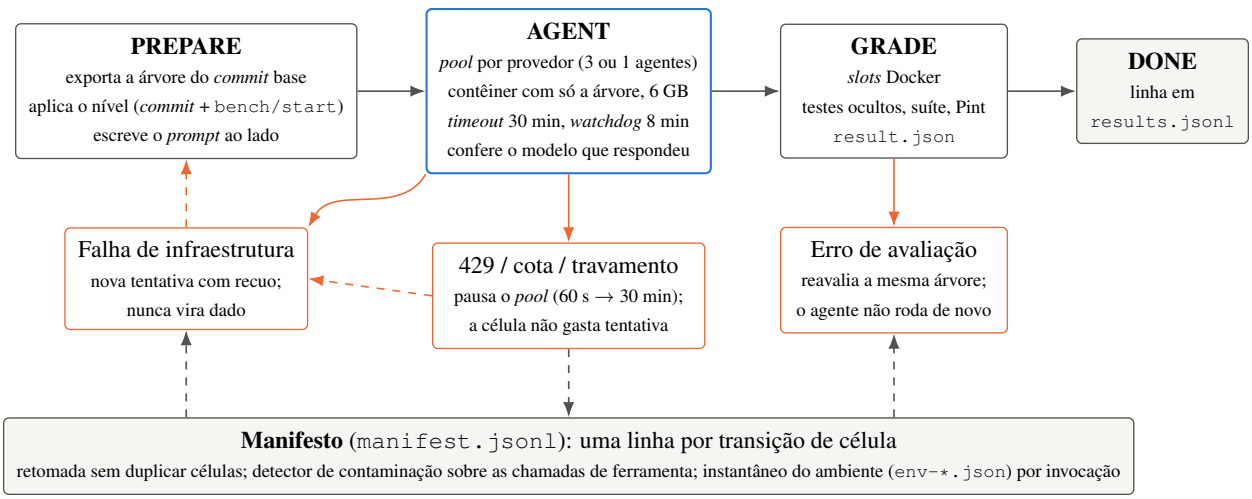
PREPARE
exporta a árvore do commit base
aplica o nível (commit + bench/start)
escreve o prompt ao lado
AGENT
pool por provedor (3 ou 1 agentes)
contêiner com só a árvore, 6 GB
timeout 30 min, watchdog 8 min
confere o modelo que respondeu
GRADE
slots Docker
testes ocultos, suíte, Pint
result.json
DONE
linha em
results.jsonl
Falha de infraestrutura
nova tentativa com recuo;
nunca vira dado
429 / cota / travamento
pausa o pool (60 s → 30 min);
a célula não gasta tentativa
Erro de avaliação
reavalia a mesma árvore;
o agente não roda de novo
Manifesto (manifest.jsonl): uma linha por transição de célula
retomada sem duplicar células; detector de contaminação sobre as chamadas de ferramenta; instantâneo do ambiente (env-*.json) por invocação